ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE MADRID

Introducción a ML con Python

Eduardo Fernández Carrión, PhD

Profesor

Eduardo Fernández Carrión

Lead Data Scientist | ML/AI Engineer

PhD en Métodos Estadístico-Matemáticos para el Tratamiento Computacional de la Información (UCM)

Ciencias Matemáticas (UCM)

Ingeniería Informática (URJC)

Tipos de Problemas

Diferencias entre tipos de Problemas

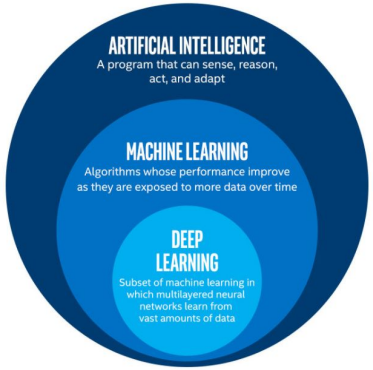

Aprendizaje supervisado:

- Problema de Clasificación: Cuando la variable objetivo es categórica
- Problema de Regresión: Cuando la variable objetivo es numérica

Aprendizaje no supervisado:

- Clusterización: Cuando no hay variable objetivo

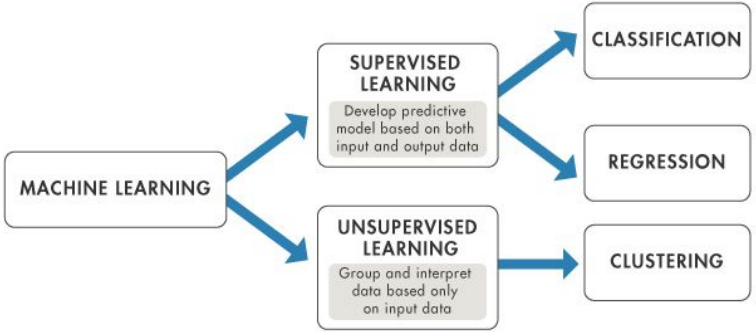

Data Science Lifecycle

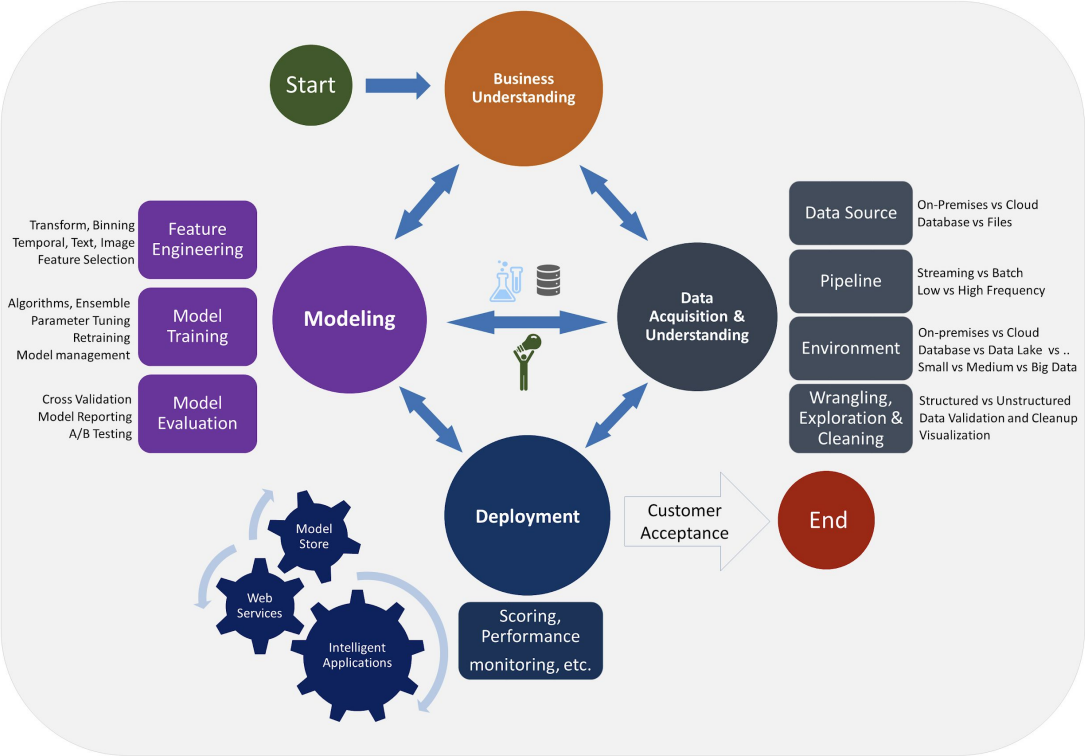

Modeling Process

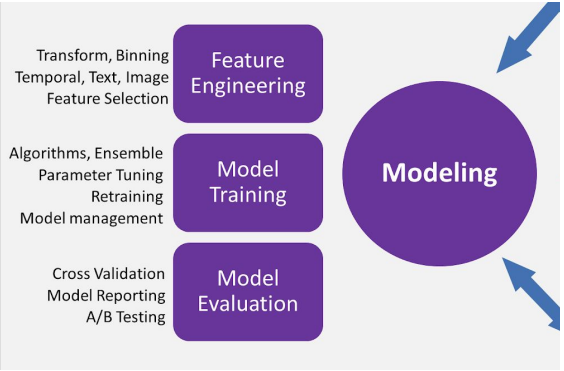

Para hacer un buen modelo de ML, una vez entendido el problema tenemos que:

1. Decidir cuáles serán las variables predictoras y la variable objetivo. Pero, por el camino, podría ser que
   a. tuviéramos que limpiar datos, o que
   b. tuviéramos que transformar algunas variables.
2. Probar diferentes algoritmos predictivos, teniendo en cuenta que existen,
   a. diferentes parametrizaciones de cada modelo,
   b. diferentes formas de entrenar un modelo
   c. diferentes métricas de evaluación de un modelo

Modeling Process

data preparation	model training
data exploring	feature selection
data cleansing	cross validation
data transformation	metric
	model selection
	model tuning

80% time

20% time

Datasets

Breast Cancer (Tema 2):

https://raw.githubusercontent.com/eduardofc/data/main/breast_cancer_data.csv

Titanic (Tema 3):

https://raw.githubusercontent.com/eduardofc/data/main/titanic-2.csv

Diabetes (Tema 4):

https://raw.githubusercontent.com/eduardofc/data/main/diabetes.csv

SciPy

Python Ecosystem for Data Science

pandas library:

https://pandas.pydata.org/docs/user_guide/index.html

numpy library:

https://numpy.org/doc/stable/reference/index.html

sklearn library:

https://scikit-learn.org/stable/

imbalanced learn library:

https://imbalanced-learn.org/stable/#

Entorno Virtual

Para crear el entorno virtual, nos apoyaremos en los siguientes comandos:

- Para ver el listado de entornos virtuales creados en la computadora:

```
conda env list
```

- Para crear un entorno virtual nuevo llamado "*ml_python*" que tenga la versión 3.10.13 de python:

```
conda create -n ml_python python=3.10.13
```

- Para activar el entorno virtual que hemos creado:

```
conda activate ml_python
```

- Para instalar las librerías que necesitaremos en este curso:

```
pip install pandas==2.2.3 numpy==2.1.2 scikit-learn==1.5.2
imbalanced-learn==0.12.3 matplotlib==3.9.2 seaborn==0.13.2 notebook==6.5.6
```

Ejemplo End-2-End

Clasificación

load data

fit model

save model

```
digits = datasets.load_digits()
features = digits.data
target = digits.target

model = LogisticRegression()
model.fit(features, target)
model.score(features, target)

dump(model, open('./models/2021-01-22-lr.pkl', 'wb'))
```

Ejemplo End-to-End

Clasificación

load data

split data

fit model

save model

```
digits = datasets.load_digits()
features = digits.data
target = digits.target

features_train, features_test, target_train, target_test = train_test_split(features, target)

model = LogisticRegression()
model.fit(features_train, target_train)
model.score(features_test, target_test)

dump(model, open('./models/2021-01-22-lr.pkl', 'wb'))
```

Ejemplo End-to-End

Clasificación

- load data
- split data
- transform data
- fit model
- save model

```
digits = datasets.load_digits()
features = digits.data
target = digits.target

features_train, features_test, target_train, target_test = train_test_split(features, target)

model = LogisticRegression()
standarizer = StandardScaler()
pipeline = Pipeline([('standarizer', standardizer),
                     ('lr', model)])

pipeline.fit(features_train, target_train)
pipeline.score(features_test, target_test)

dump(pipeline, open('./models/2021-01-22-lr-standscaler.pkl', 'wb'))
```

Generación Números Aleatorios

Seed

Muchos algoritmos necesitan, en algún momento, generar números aleatorios (basados o no en distribuciones conocidas).

El resultado de estos algoritmos, por tanto, puede ser distinto cada vez.

Para controlar que la generación de números aleatorios pueda replicarse, utilizamos semillas (seeds).

```
for i in range(5):
    n = np.random.rand()
    print(n)
```

```
0.5843822841126954
0.9487017425250871
0.31866667163743956
0.10756070569052278
0.5452390454746973
```

```
for i in range(5):
    np.random.seed(10)
    n = np.random.rand()
    print(n)
```

```
0.771320643266746
0.771320643266746
0.771320643266746
0.771320643266746
0.771320643266746
```

Generación Números Aleatorios

Seed

Generalmente, en scikit-learn, se utiliza el parámetro *random_state* para controlar las semillas.

```
digits = datasets.load_digits()
features = digits.data
target = digits.target

X_train, X_test, y_train, y_test = train_test_split(features, target, random_state=1)

model = LogisticRegression(random_state=1)
model.fit(X_train, y_train)
model.score(X_test, y_test)
```

```
0.9688888888888889
```

Comparación de Algoritmos

En scikit-learn, hay una colección extensa de algoritmos para cada tipo de problema:

https://scikit-learn.org/stable/index.html

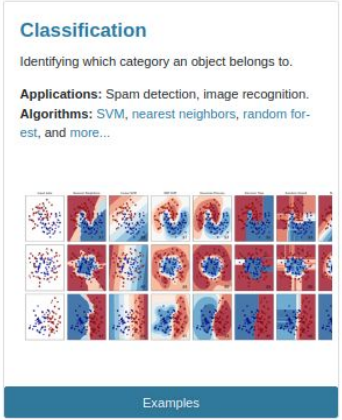

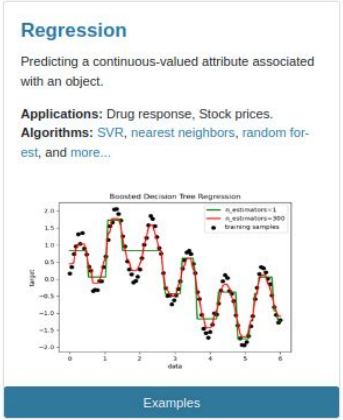

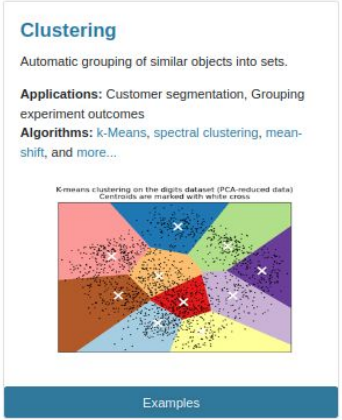

Comparación de Algoritmos

Clasificación

Un primer trabajo del data scientist sería evaluar un conjunto de modelos.

```
models = []
models.append(('LR', LogisticRegression()))
models.append(('LDA', LinearDiscriminantAnalysis()))
models.append(('KNN', KNeighborsClassifier()))
models.append(('DTC', DecisionTreeClassifier()))
models.append(('NB', GaussianNB()))
models.append(('RFC', RandomForestClassifier()))
models.append(('SVM', SVC()))

X_train, X_test, y_train, y_test = train_test_split(features, target)

for name, model in models:
    model.fit(X_train, y_train)
    score = model.score(X_test, y_test)
    print(name, ': ', str(score))
```

```
LR :  0.9688888888888889
LDA :  0.9666666666666667
KNN :  0.9933333333333333
DTC :  0.8644444444444445
NB :  0.8533333333333334
RFC :  0.98
SVM :  0.9888888888888889
```

ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE MADRID