Guía de estudio. Módulo Machine Learning, Redes Neuronales

Material:

1. Documentación:
   - *Machine Learning_Intro*, algunas nociones básicas sobre qué es el ML, qué herramientas, modelos y medidas se utilizan.
   - *Validación y comparación*, para profundizar en estructuras y medidas de evaluación y comparación de modelos de ML. También incluye conceptos básicos sobre problemas de optimización. En *Machine Learning_Intro* se mencionan algunos conceptos en los que se profundiza en este documento.
   - *Machine Learning_RedesNeuronales_Inma_Python*, toda la información teórica sobre redes neuronales
   - *IMPRESCINDIBLES* incluye las diapositivas más importantes, que resumen los conceptos imprescindibles de esta parte del módulo
   - *transformers_introduccion*¸este documento no es parte propia del contenido de este módulo. Se proporciona a modo información general que pueda resultar de interés.
2. Scripts Jupyter: esta parte del módulo se centra en los contenidos conceptuales sobre las redes neuronales, su tuneo, análisis de parámetros y evaluación. Se proporcionan algunos notebooks de Jupyter en los que se presenten las herramientas más sencillas para llevar a cabo un proceso completo de análisis de redes neuronales son Python, específicamente usando la librería *scikit-learn.* Se proporciona un script con algunos conceptos básicos sobre EDA y FE que ya se deberían conocer de módulos anteriores. Los archivos 03-*Redes_clasificación*, 04-R*edes_clasificación*, son equivalentes a *05-Redes_regresión*, *06-Redes_regresión_2*, respectivamente, para problemas distintos y están desarrollados con *scikit-learn.* El archivo *07_Redes_clasificacion_keras*¸ hace una breve introducción a la librería *keras.* Esta librería es mucho más compleja que *sklearn* y está centrada en el uso de redes neuronales, por lo que no es tan sencillo comparar los modelos obtenidos frente a otras técnicas de una forma tan compacta como lo hace *sklearn.* Por otro lado, sí que ofrece un tuneo mucho más detallado de hiperparámetros. No obstante, para los problemas que se plantean de clasificación binaria y regresión, no es necesario alcanzar ese nivel de detalle, por lo que simplemente se presenta *keras* y se explica mediante un ejemplo, sin profundizar. En módulos de *Deep learning* se enseñará cómo trabajar con estos modelos más complejos.

IMPORTANTE: la puesta en producción y programación eficaz de los modelos se presentará en la última parte de este módulo de ML. En esta primera sección se pretende que se entienda conceptualmente el modelo, que se aprenda a analizar su estabilidad, capacidad predictiva y robustez, comprendiendo el papel de los parámetros involucrados.

3. Vídeos: los títulos de los vídeos se corresponden con el nombre del archivo que acompaña, de manera que el vídeo *Machine Learning_introducción* es la explicación del documento *Machine Learning_Intro*. La explicación del contenido presentado en *Machine Learning_RedesNeuronales_Inma_Python* está divida en los vídeos que empiezan con *RedesNeuronales_* El número que aparece en cada vídeo se corresponde con la sección del documento a la que se corresponde.

4. Datasets: se ofrecen algunos archivos de datasets de prueba. En la sección 9 de *Machine Learning_RedesNeuronales_Inma_Python* se proporcionan algunos enlaces a través de los cuales obtener más conjuntos de datos para hacer pruebas.

Lo primero que se debe hacer es comprender los conceptos explicados en la introducción (1) y comparación y validación (2). Todo ello será imprescindible para el correcto seguimiento del módulo de machine learning (no son ideas propias de las redes neuronales).

A continuación, se puede abordar en el orden marcado por las secciones el contenido presentado en el archivo *RedesNeuronales.* La propia documentación marcará cuando pasar a cada notebook Jupyter. Aunque los conceptos "teóricos" se presentan en la documentación, los notebook también incluyen bastantes aclaraciones y explicaciones, además de la descripción y uso de los parámetros involucrados en cada parte.

Se recomienda ver todos los vídeos, leer la documentación y entender bien la información de los notebook. A continuación, sería recomendable ser capaz de reproducir el proceso completo para algún dataset diferente. Esto permitirá hacer una autoevaluación objetiva de los conocimientos adquiridos.

No se incluyen vídeos propios para los notebooks de regresión porque la idea y ejecución es idéntica a las explicaciones de clasificación, simplemente hay que utilizar la función MLPRegressor(), y modificar las métricas de evaluación.

"Hoja de ruta en problemas de ML"

(1) CARGAR BASE DE DATOS Y CONOCER FRECUENCIA DE CLASES O DISTRIBUCIÓN DE ACUERDO CON EL TIPO DE PROBLEMA.

(2) DIVIR TRAIN, TEST Y COMPROBAR SI LA DISTRIBUCIÓN DE LA VARIABLE DEPENDIENTE ES SIMILAR EN AMBOS SETS.

(3) AJUSTAR EL MODELO Y VALORAR LAS NECESIDADES DE INVESTIGACIÓN PARA DAR MÁS PESO A UNAS MEDIDAS DE BONDAD DE AJUSTE CON RESPECTO A OTRAS.

(3.1) APLICAR VALIDACIÓN CRUZADA Y, EN CASO DE NECESIDAD, UN GRIDSEARCH PARA CONOCER LAS BONDADES DE AJUSTE PARA DISTINTAS PARAMETRIZACIONES.

(4) HACER PREDICCIONES SOBRE TRAIN Y TEST CON EL FIN DE OBSERVAR EL POSIBLE SOBREAJUSTE. VALORAR EN TEST LA CAPACIDAD PREDICTIVA DEL MODELO.

(5) SELECCIONAR LAS ALTERNATIVAS QUE MÁS NOS INTERESEN POR SU BONDAD DE AJUSTE ESPECÍFICA.

(6) MOSTRAR BOXPLOTS DE SU PERFORMANCE EN LAS DISTINTAS VALIDACIONES PARA VALORAR LA ROBUSTEZ Y TOMAR UNA DECISIÓN.

(7) HACER UN INFORME DE LA PARAMETRIZACIÓN Y BONDAD DE AJUSTE DEL MODELO FINAL SELECCIONADO.

Sobre la tarea de evaluación

El módulo de ML incluirá dos tareas de evaluación. Una relativa a la parte correspondiente a la explicación de los modelos y sus parametrizaciones, que abarcará el contenido de las tres primeras semanas, y que será corregida por los profesores que imparten esta parte (redes neuronales, SVM y modelos de ensamblado, árboles y modelos de ensamblado de árboles).

La otra tarea será relativa a la última parte del módulo, centrada en la puesta en producción y programación eficiente.